UNIWERSYTET WSB MERITO WE WROCŁAWIU

PROJEKT KIERUNKOWY

wykonany w ramach studiów podyplomowych

Artificial intelligence. Machine learning

Projekt i weryfikacja prototypu systemu klasy TinyML do rozpoznawania odgłosów zwierząt, bazującego na architekturze STM32.

Autor Projektu:
Bartosz Dykiert
Nr albumu: 53037

Opiekun Projektu:
Dr. inż Kamil Musiał

Wrocław, 2026

Spis treści

1 Wprowadzenie **4**

2 Sieć wykorzystana w projekcie **4**

2.1 Opis sieci neuronowej 4

2.2 Parametry analizy sygnału i ekstrakcja cech 5

2.3 Dane treningowe 6

2.4 Architektura sieci neuronowej 7

2.5 Proces treningowy i callbacki 8

2.6 Konwersja i generowanie plików nagłówkowych dla C 9

3 Aplikacja dekstopowa **10**

3.1 Funkcjonalność interfejsu graficznego 11

4 Oprogramowanie urządzenia **12**

4.1 Główna pętla programu na STM32 15

5 Testy sieci, aplikacji i urządzenia **16**

Spis rysunków

1 Funkcja ekstrakcji cech 6
2 Podział danych treningowych 7
3 Architektura sieci neuronowej 8
4 Proces treningowy - callbacki 9
5 Pliki nagłówkowe dla C 10
6 Ekran główny aplikacji 11
7 Ustawienia zegarow - 1. 13
8 Ustawienia zegarow - 2. 13
9 X cube AI 14
10 Urządzenie wbudowane 14
11 Główna pętla programu na STM32 15
12 Funkcja predykcji z pliku 16
13 Funkcja predykcji z GPT 16
14 Testowanie wszystkich plików za pomocą własnej sieci 17
15 Porównanie predykcji między własną sięcią a modelem GPT 4o audio preview . 17
16 Działanie urządzenia 18
17 Debugowanie urządzenia 18

1 Wprowadzenie

Celem niniejszego projektu dyplomowego było zaprojektowanie i implementacja systemu rozpoznawania dźwięków zwierząt działającego w środowisku systemów wbudowanych. System oparto na mikrokontrolerze STM32 nucle-H753ZI oraz sieci neuronowej stworzonej z użyciem bibliotek tensorflow, numpy oraz sklearn. Projekt składa się z aplikacji na komputer oraz urządzenia wbudowanego. Aplikacja służy do łatwego wizualizowannia danych odbieranych z mikrokontrolera oraz do porównania wyników predykcji z użyciem sieci neuronowej stworzonej na potrzeby projektu oraz z wykorzystaniem platformy open AI w ramach, której został wykorzystany model językowy "gpt 4o audio preview". W ramach pracy zrealizowano akwizycję sygnału audio, ekstrakcję cech MFCC, klasyfikację dźwięków oraz wizualizację wyników na urządzeniu i aplikacji.

2 Sieć wykorzystana w projekcie

Sieć została stworzona z IDE visual studio code z wykorzystaniem języka Python i bibliotek służących do uczenia maszynowego: tensorflow i sklearn. Dane użyte do nauki sieci pochodzą z publicznego zbioru **ESC-50**. Wybór klasy o najwyższym prawdopodobieństwie odbywa się poprzez operację:

$$\hat{c} = \arg\max_i(y_i) \tag{1}$$

gdzie:

- y_i – wartość wyjścia sieci neuronowej odpowiadająca i-tej klasie,
- $\hat{c}$ – klasa przypisana do analizowanego sygnału.

2.1 Opis sieci neuronowej

W ramach projektu opracowano skrypt w języku Python, wykorzystujący biblioteki TensorFlow/Keras, których zadaniem jest przeprowadzenie pełnego cyklu szkoleniowego sieci neuronowej oraz eksport parametrów do środowiska systemu wbudowanego. przygotowanie zbioru danych i ekstrakcji cech rozpoczyna się od wczytania surowych plików dźwiękowych w formacie WAV pobranych z zbioru **ESC-50**. Kluczowym etapem jest ekstrakcja cech akustycznych za pomocą funkcji extrac_features. Z każdego nagrania wyznaczane są współczynniki MFCC (ang. Mel-Frequency Cepstral Coefficients). Aby poprawić proces uczenia został zoptymalizowany o wykorzystanie mechanizmu kontrolnego (callback:EarlyStopping). Wszystkie pliki dźwiękowe są w formacie .wav. Następnie została przeprowadzona konwersja do formatu TensorFlow Lite

i wygenerowanie plików nagłówkocych użytych do łatwiejszej implementacji ekstrakcji cech na STM32.

2.2 Parametry analizy sygnału i ekstrakcja cech

Parametry analizy czasowo-częstotliwościowej zostały zdefiniowane w Tabela 1.

Tabela 1: Parametry ekstrakcji cech sygnału audio

Parametr	**Wartość**
Częstotliwość próbkowania (f_s)	44100 Hz
Rozmiar okna FFT (N_{FFT})	1024 próbki
Długość kroku (*hop length*)	512 próbek
Liczba filtrów melowych (N_{mels})	40
Liczba współczynników MFCC (N_{mfcc})	40

Funkcja `extract_features` realizuje przekształcenie surowego sygnału audio w wektor cech o rozmiarze 80. Składa się on z 40 wartości średnich oraz 40 wartości odchylenia standardowego współczynników MFCC obliczonych dla wszystkich ramek czasowych nagrania.

```python
def extract_features(path, n_mfcc=N_MFCC, n_fft=N_FFT, hop_length=HOP_LENGTH, n_mels=N_MELS, sr=SAMPLE_RATE):
    import soundfile as sf
    from scipy.fftpack import dct

    try:
        y, sr = sf.read(path)
        y = y.astype(np.float32)

        # Konwersja stereo -> mono
        if y.ndim == 2:
            y = y.mean(axis=1)

        # Ramkowanie + Hamming
        frames = []
        window = get_window("hamming", n_fft, fftbins=True)
        for start in range(0, len(y) - n_fft + 1, hop_length):
            frame = y[start:start+n_fft] * window
            frames.append(frame)
        frames = np.array(frames)

        # FFT + magnituda
        mag = np.abs(rfft(frames, n=n_fft))

        # Mel filter bank
        mel_fb = librosa.filters.mel(sr=sr, n_fft=n_fft, n_mels=n_mels)
        mel_energy = np.log(np.maximum(mag @ mel_fb.T, 1e-12))

        # DCT -> MFCC
        mfcc = dct(mel_energy, type=2, axis=1, norm='ortho')[:, :n_mfcc]

        # średnia + std
        features = np.hstack([mfcc.mean(axis=0), mfcc.std(axis=0)])
        return features

    except Exception as e:
        print(f"[WARN] Błąd podczas przetwarzania pliku {path}: {e}")
        return None
```

Rysunek 1: Funkcja ekstrakcji cech

2.3 Dane treningowe

Do wyuczenia sieci użyto uczenia etykietowanego. Dane zostały podzielone na: 60% dane

- Dane trenigowe - 80%
- Dane walidacyjne - 20%
- Dane testowe - 20%

Zastosowano StandardScaler i zapis do formatu .joblib, zapewniając spójność przetwarzania danych w fazie predykcji.

```python
le = LabelEncoder()
y_enc = le.fit_transform(y)

# podzial danych
X_train_full, X_test, y_train_full, y_test = train_test_split(
    X, y_enc,
    test_size=0.2,
    stratify=y_enc,
    random_state=RANDOM_STATE
)

X_train, X_val, y_train, y_val = train_test_split(
    X_train_full, y_train_full,
    test_size=0.25,
    stratify=y_train_full,
    random_state=RANDOM_STATE
)

#skalowanie
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_val   = scaler.transform(X_val)
X_test  = scaler.transform(X_test)

joblib.dump(le, os.path.join(OUTPUT_DIR, "label_encoder.joblib"))
joblib.dump(scaler, os.path.join(OUTPUT_DIR, "scaler.joblib"))
print("[INFO] Zapisano label encoder i scaler.")
```

Rysunek 2: Podział danych treningowych

2.4 Architektura sieci neuronowej

Sieć neuronowa składa się z:

- **Warstwy wejściowej**: rozmiar zgodny z liczbą cech (80).
- **Blok 1**: Warstwa gęsta (256 neuronów, ReLU), Batch Normalization, Dropout (0.3).
- **Blok 2**: Warstwa gęsta (128 neuronów, ReLU), Batch Normalization, Dropout (0.3).
- **Blok 3**: Warstwa gęsta (64 neurony, ReLU), Dropout (0.2).
- **Warstwy wyjściowej**: Warstwa gęsta z funkcją *Softmax*, liczba neuronów odpowiada

liczbie rozpoznawanych klas.

```
num_classes = len(np.unique(y_enc))
input_dim = X_train.shape[1]

model = keras.Sequential([
    keras.layers.Input(shape=(input_dim,)),

    keras.layers.Dense(256, activation="relu"),
    keras.layers.BatchNormalization(),
    keras.layers.Dropout(0.3),

    keras.layers.Dense(128, activation="relu"),
    keras.layers.BatchNormalization(),
    keras.layers.Dropout(0.3),

    keras.layers.Dense(64, activation="relu"),
    keras.layers.Dropout(0.2),

    keras.layers.Dense(num_classes, activation="softmax")
])

model.compile(
    optimizer=keras.optimizers.Adam(learning_rate=1e-3),
    loss="sparse_categorical_crossentropy",
    metrics=["accuracy"]
)

model.summary()
```

Rysunek 3: Architektura sieci neuronowej

2.5 Proces treningowy i callbacki

Model trenowany był z wykorzystaniem optymalizatora **Adam** (learning rate = 10^{-3}) oraz funkcji straty *sparse categorical crossentropy*. W celu optymalizacji procesu wykorzystano trzy mechanizmy kontrolne:

1. **EarlyStopping**: zatrzymanie treningu po 20 epokach braku poprawy błędu walidacyjnego.
2. **ModelCheckpoint**: zapisywanie wyłącznie wag modelu o najlepszych parametrach (*best model*).

3. **ReduceLROnPlateau**: redukcja współczynnika uczenia o mnożnik 0.3 w przypadku stagnacji procesu minimalizacji funkcji celu.

```
callbacks = [
    keras.callbacks.EarlyStopping(
        monitor="val_loss",
        patience=20,
        restore_best_weights=True,
        verbose=1
    ),

    keras.callbacks.ModelCheckpoint(
        filepath=os.path.join(OUTPUT_DIR, "best_model.h5"),
        monitor="val_loss",
        save_best_only=True,
        verbose=1
    ),

    keras.callbacks.ReduceLROnPlateau(
        monitor="val_loss",
        factor=0.3,
        patience=10,
        verbose=1,
        min_lr=1e-6
    )
]

history = model.fit(
    X_train, y_train,
    validation_data=(X_val, y_val),
    epochs=args.epochs,
    batch_size=args.batch_size,
    verbose=2,
    callbacks=callbacks
)
```

Rysunek 4: Proces treningowy - callbacki

2.6 Konwersja i generowanie plików nagłówkowych dla C

Finalny model jest eksportowany do formatu `.tflite`.

Kluczowym elementem skryptu jest automatyczne generowanie plików nagłówkowych (`.h`), które przenoszą parametry wyliczone w Pythonie bezpośrednio do kodu C w środowisku STM32CubeIDE:

- `scaler_params.h`: zawiera parametry μ oraz σ użyte przez `StandardScaler`.
- `mel_filter_banks.h`: zawiera statyczną macierz filtrów melowych.
- `dct_matrix.h`: zawiera predefiniowaną macierz do obliczeń transformaty kosinusowej.

- `hamming_window.h`: zawiera tablicę wag okna Hamminga.

```python
with open(os.path.join(OUTPUT_DIR, "mel_filter_banks.h"), "w") as f:
    f.write("#pragma once\n\n")
    f.write("// Autogenerated Mel filter banks\n\n")
    f.write(f"#define NUM_MEL_FILTERS {n_mels}\n")
    f.write(f"#define FFT_BINS {n_fft//2+1}\n\n")
    f.write(fmt_matrix("mel_filter_banks", mel_filter))

print("Wygenerowano mel_filter_banks.h")

dct_matrix_manual = np.zeros((n_mfcc, n_mels), dtype=np.float32)
for i in range(n_mfcc):
    dct_matrix_manual[i, :] = np.cos(np.pi * i / n_mels * (np.arange(n_mels) + 0.5))

dct_matrix_manual[0, :] *= 1.0 / np.sqrt(n_mels)
dct_matrix_manual[1:, :] *= np.sqrt(2.0 / n_mels)

with open(os.path.join(OUTPUT_DIR, "dct_matrix.h"), "w") as f:
    f.write("#pragma once\n\n")
    f.write("// Autogenerated DCT matrix\n\n")
    f.write(f"#define NUM_MFCC_COEFFS {n_mfcc}\n")
    f.write(f"#define NUM_MEL_FILTERS {n_mels}\n\n")
    f.write(fmt_matrix("dct_matrix", dct_matrix_manual))

print("Wygenerowano dct_matrix.h")

hamming = np.hamming(FRAME_SIZE).astype(np.float32)

with open(os.path.join(OUTPUT_DIR, "hamming_window.h"), "w") as f:
    f.write("#pragma once\n\n")
    f.write("// Autogenerated Hamming window\n\n")
    f.write(f"#define FRAME_SIZE {FRAME_SIZE}\n\n")
    f.write(fmt_array("hamming_window", hamming))

print("Wygenerowano hamming_window.h")

with open(os.path.join(OUTPUT_DIR, "scaler_params.h"), "w") as f:
    f.write("#pragma once\n\n")
    f.write("// Autogenerated by Python script\n\n")
    f.write(f"#define FEATURE_COUNT {X_train.shape[1]}\n\n")
    f.write(fmt_array("SCALER_MEAN", mean))
    f.write("\n")
    f.write(fmt_array("SCALER_SCALE", scale))
    f.write("\n")
    f.write(fmt_int_array("SCALER_Q14_MEAN", X_train_q14.mean(axis=0).astype(np.int16)))
    f.write("\n")
    f.write(f"static const int SCALER_LEN = {len(mean)};\n\n")
    f.write("static const char *LABELS[] = {\n")
    for lab in labels:
        f.write(f"    \"{lab}\",\n")
    f.write("};\n")
    f.write(f"static const int NUM_LABELS = {len(labels)};\n")

print("Wygenerowano scaler_params.h (Q14 ADC)")
```

Rysunek 5: Pliki nagłówkowe dla C

3 Aplikacja dekstopowa

W celu obsługi systemu oraz wizualizacji wyników opracowano aplikację desktopową z graficznym interfejsem użytkownika (GUI). Interfejs został zaprojektowany w środowisku Qt Designer i zaimplementowany w języku Python przy użyciu biblioteki `PyQt5`. Rysunek **6**. przestawia ekran główny aplikacji.

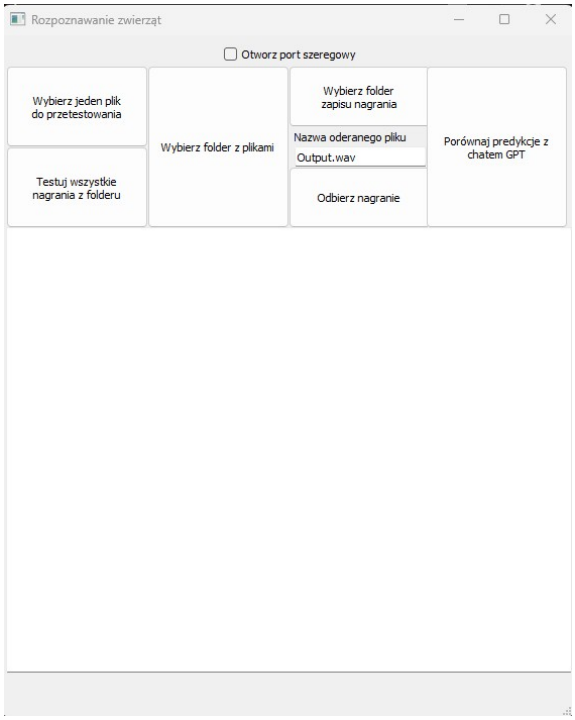

Rysunek 6: Ekran główny aplikacji

3.1 Funkcjonalność interfejsu graficznego

Główne okno aplikacji zostało stworzone w sposób umożliwiający zarówno testowanie stworzonej sieci na stm32 i wyświetlanie wyników predykcji. Dodatkowym elementem jest możliwość sprawdzenia oceny nagrania wraz z "gpt 4o audio preview". Elementy interfejsu:

- **Otworz port szeregowy** (pole wyboru / checkbox) - służy otwarciu portu szeregowego w celu komunikacji z mikrokontrolerem.
- **Wybierz jeden plik do przetestowania** - wybieramy jeden plik do przetestowania sieci użytej w urządzeniu.
- **Testuj wszystkie nagrania z folderu** - testujemy wszystkie pliki nagrań.
- **Wybierz folder z plikami** - wybieramy folder z plikami nagrań.
- **Wybierz folder zapisu nagrania** - wybieramy folder, gdzie ma zostać zapisane nagranie z pobranych próbek przez mikrokontroler
- **Nazwa odebranego pliku** (pole tekstowe: Output.wav) - nazwa odebranego pliku.
- **Odbierz nagranie** - klikamy ten przycisk, aby powiadomić aplikacje, że zaraz nadejdą dane z urządzenia. Po kliknięciu tego przycisku należy kliknąć przycisk wyślij na mikrokontrolerze.

- **Porównaj predykcje z chatem GPT** - wybranie pliku i wysłanie promptu do modelu GPT, aby wyświetlić wynik predykcji od modelu GPT.
- **Pole tekstowe** - Do wyświetlania komunikatów predykcji oraz komunikatów błędów.

4 Oprogramowanie urządzenia

Mikrokontroler został zaprogramowany z użyciem STM32CubeIDE. Przycisk do nagrywania został zaprogramowany na wejściu PA3, odczyt danych z mikrofonu został przeprowadzony przez ADC na wejściu PA4, przycisk do wyświetlenia predykcji na wyświetlaczu SSD1306 został zaprogramowany na wejściu PD1, przycisk do wysłania nagrania do komputera na wejściu PD0. Do Komikacji z wykorzystaniem interfejsu I2C zostały wykorzystane wejścia PB8 i PB9. Wejścia PB6 i PB15 zostały użyte do komunikacji USART z komputerem. Na Rysunek **7**. oraz Rysunek **8**. są przedstawione ustawienia zegarów. Rysunek **10**. przedstawia wykonane urządzenie. X-CUBE_AI zostało również skonfigurowane do używania wcześniej stworzonej sieci (Rysunek **9**).

Urządzenie składa się z:

- Trzech przycisków służących kolejno **"1"** do nagrania dźwięku, **"2"** do wysłania nagrania po porcie szeregowym, **"3"**, wyświetlenia predykcji dżwięku.
- Wyświetlacza SSD1306 do wyświetlania komunikatów.
- Mikrofonu elektretowego ze wzmacniaczem MAX9814 do nagrywania dźwięków.
- Pinów RX i TX do komunikacji z komputertem z wykorzystaniem komunikacji USART.

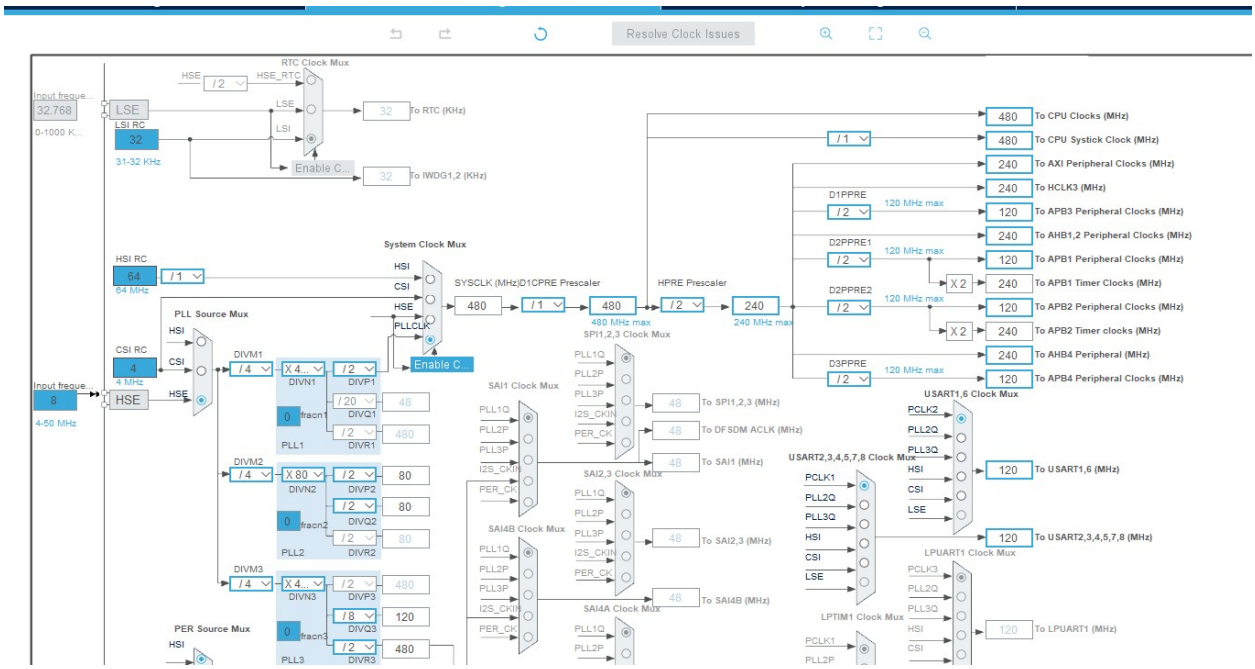

Rysunek 7: Ustawienia zegarow - 1.

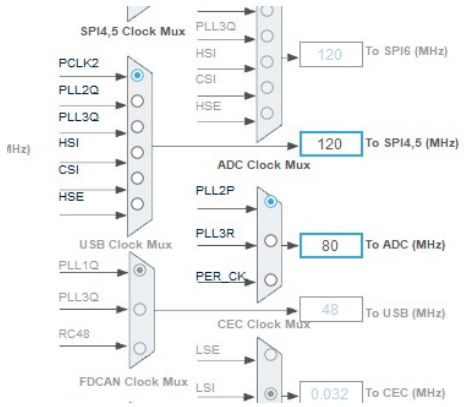

Rysunek 8: Ustawienia zegarow - 2.

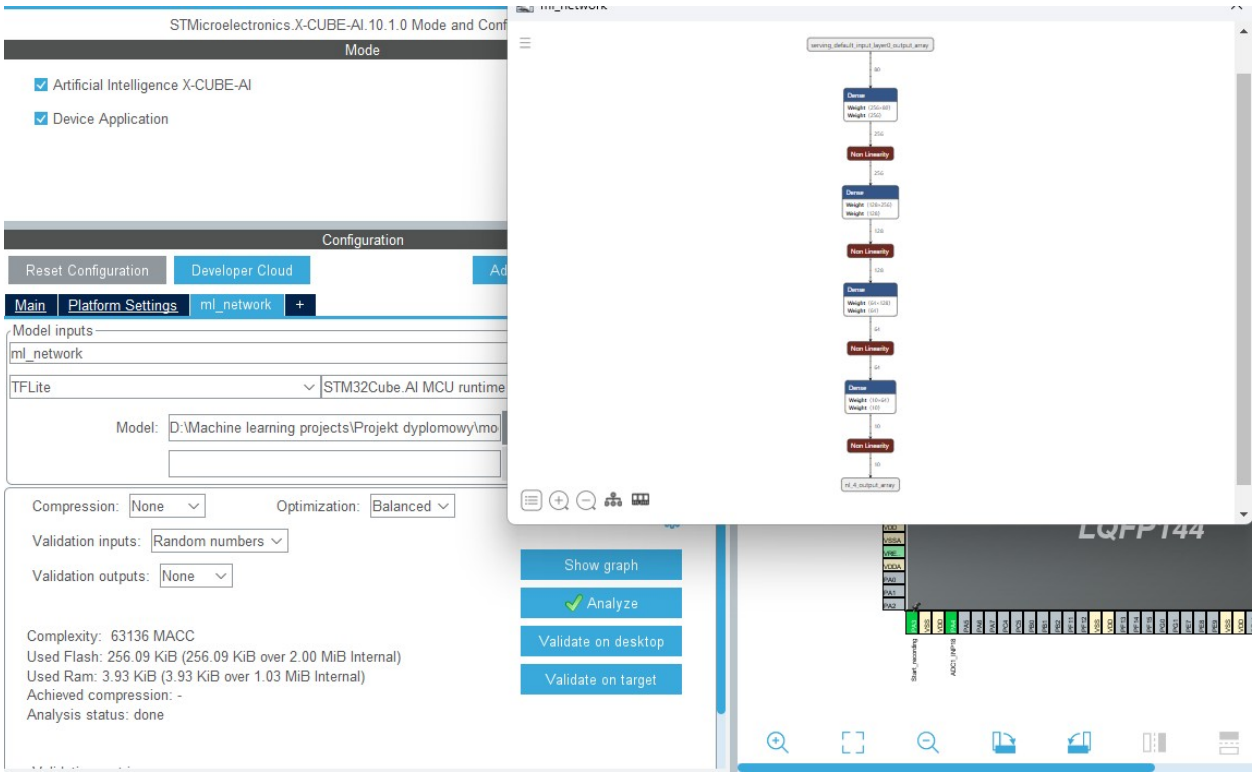

Rysunek 9: X cube AI

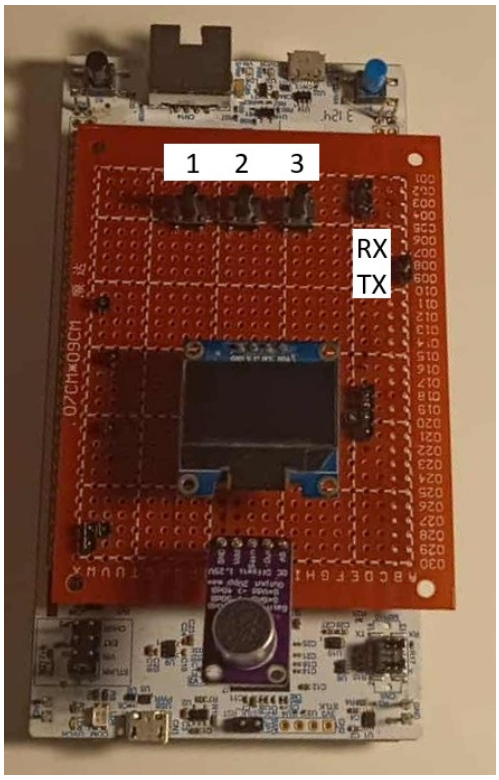

Rysunek 10: Urządzenie wbudowane

4.1 Główna pętla programu na STM32

```
/* Initialize all configured peripherals */
MX_GPIO_Init();
MX_DMA_Init();
MX_ADC1_Init();
MX_USART1_UART_Init();
MX_TIM1_Init();
MX_RAMECC_Init();
MX_I2C1_Init();
MX_X_CUBE_AI_Init();
/* USER CODE BEGIN 2 */

  counter = 0;
  SCB->CPACR |= ((3UL << 10*2)|(3UL << 11*2)); // włącz FPU
  init_network();
  debug_msg("FFT initialization\r\n");
  if (arm_rfft_fast_init_f32(&fft_instance, FRAME_SIZE) != ARM_MATH_SUCCESS) {
      debug_msg("FFT init failed!\r\n");
  }
  if (ssd1306_Init() == 1)
  {
      ssd1306_SetCursor(0,0);
      refreash_display("Initializated");
      HAL_Delay(500);
      debug_msg("SSD1306 success initalizated\r\n");

  }
  else
  {
      debug_msg("SSD1306 wasn't initalizated\r\n");
  }

  app_states = State_idle;

/* USER CODE END 2 */
```

```
switch(app_states)
{
case State_idle:
    debug_msg("IDLE: Press button to start\r\n");
    refreash_display("IDLE");
    break;
case State_recording:
    refreash_display("Recording");
    HAL_Delay(100);
    HAL_TIM_Base_Start(&htim1);   // start timera do delay_us
    debug_msg("Recording");
    StartRecording();
    debug_msg("Recording finished\r\n");
    break;
case State_send:
    refreash_display("Sending");
    HAL_TIM_Base_Stop(&htim1); // Zatrzymaj timer
    SendAllChunks_Blocking();
    send_index =5;
    break;
case State_AI_result:
    refreash_display("AI_result");
    run_inference(audio_buf,NUM_SAMPLES); // wysyłamy wynik predykcji
    app_states = State_idle;      // wracamy do stanu idle
    break;

case State_recording_and_send_chunks:
    refreash_display("send_chunks");
    break;

case State_wait_for_next_step:

    break;
```

Rysunek 11: Główna pętla programu na STM32

5 Testy sieci, aplikacji i urządzenia

W aplikcje został wbudowany skrypt do testowania wytrenowanej sieci (Rysunek. **12**). Wyniki predykcji sieci potrafią być różne od rzeczywistej, np. koń potrafi być pomylony z kotem (Rysunek. **14**). Po wysłaniu promptu do GPT (Rysunek. **??**). w odpowiedzi otrzymujemy wynik predykcji zgodny z nagraniem (Rysunek. **15**). Najlepiej są rozpoznawane żaby, kury, owce i wrony. Urządzenie zostało przetestowane w sposób, że zostały nagrywane dźwieki zwierząt z głośników z komputera, po czym na wyświetlaczu SSD1306 można było zobaczyć wynik predykcji wraz z prawdopodobieństwem(Rysunek. **16**). Urządzenie wysyła również komunikaty po porcie szeregowym. Zostało to zrealizowane w ten sposób w celu ułatwienia debugowania podczas pisania kod na mikrokontroler(Rysunek. **17**).

```python
def predict_file(self, filepath):

    features = extract_features(filepath)
    if features is None:
        return f"[WARN] Błąd podczas przetwarzania pliku: {filepath}\n"

    # Skalowanie i predykcja
    scaled_features = scaler.transform(features.reshape(1, -1)).astype(np.float32)

    interpreter.set_tensor(input_details[0]['index'], scaled_features)
    interpreter.invoke()
    predictions = interpreter.get_tensor(output_details[0]['index'])

    predicted_class_index = int(np.argmax(predictions))
    confidence = float(predictions[0][predicted_class_index])
    predicted_label = le.inverse_transform([predicted_class_index])[0]

    result = (
        f"--- Plik: {os.path.basename(filepath)} ---\n"
        f"Przewidziana kategoria: {predicted_label}\n"
        f"Pewność: {confidence:.4f}\n"
    )
    return result
```

Rysunek 12: Funkcja predykcji z pliku

```python
def predict_file_GPT(self, filepath):
    client = OpenAI(api_key=API_KEY_GPT)
    with open(filepath, "rb") as audio_file:
        encoded_audio = base64.b64encode(audio_file.read()).decode("utf-8")
    lista_zwierzat = "cat, cow, crow, dog, frog, hen, insects, pig, rooster, sheep, horse"

    try:

        response = client.chat.completions.create(
            model="gpt-4o-audio-preview",
            modalities=["text"], # Chcemy odpowiedź tekstową
            messages=[
                {
                    "role": "user",
                    "content": [
                        {"type": "text", "text": f"Listen to this audio and tell me which animal from this list it is: {lista_zwierzat}. Return only the name of the animal."},
                        {"type": "input_audio", "input_audio": {"data": encoded_audio, "format": "wav"}}
                    ]
                }
            ]
        )
    except Exception as e:
            return f"ERROR: {e}"
    # 5. Zapisanie odpowiedzi do zmiennej
    predict_result = response.choices[0].message.content.strip().lower()
    result = (
        f"--- Plik: {os.path.basename(filepath)} ---\n"
        f"Przewidziana kategoria przez GPT: {predict_result}\n"
    )
    return result
```

Rysunek 13: Funkcja predykcji z GPT

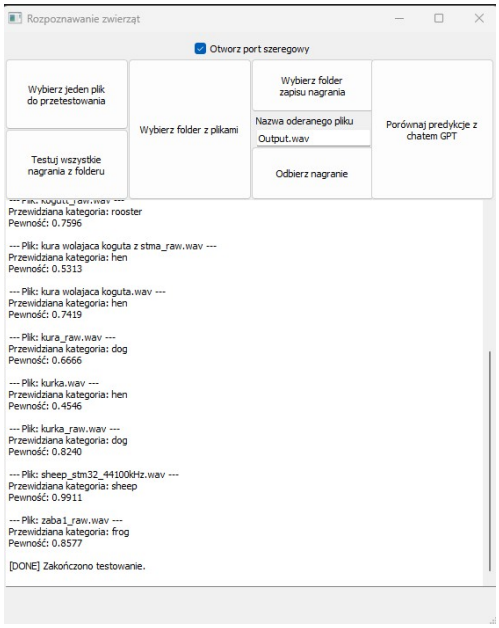

Rysunek 14: Testowanie wszystkich plików za pomocą własnej sieci

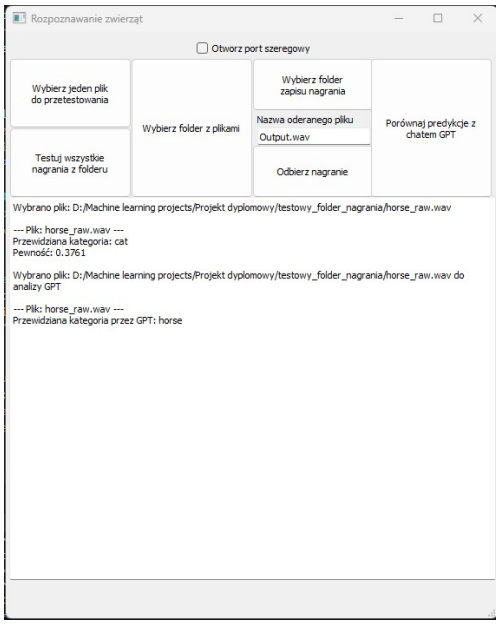

Rysunek 15: Porównanie predykcji między własną sięcią a modelem GPT 4o audio preview

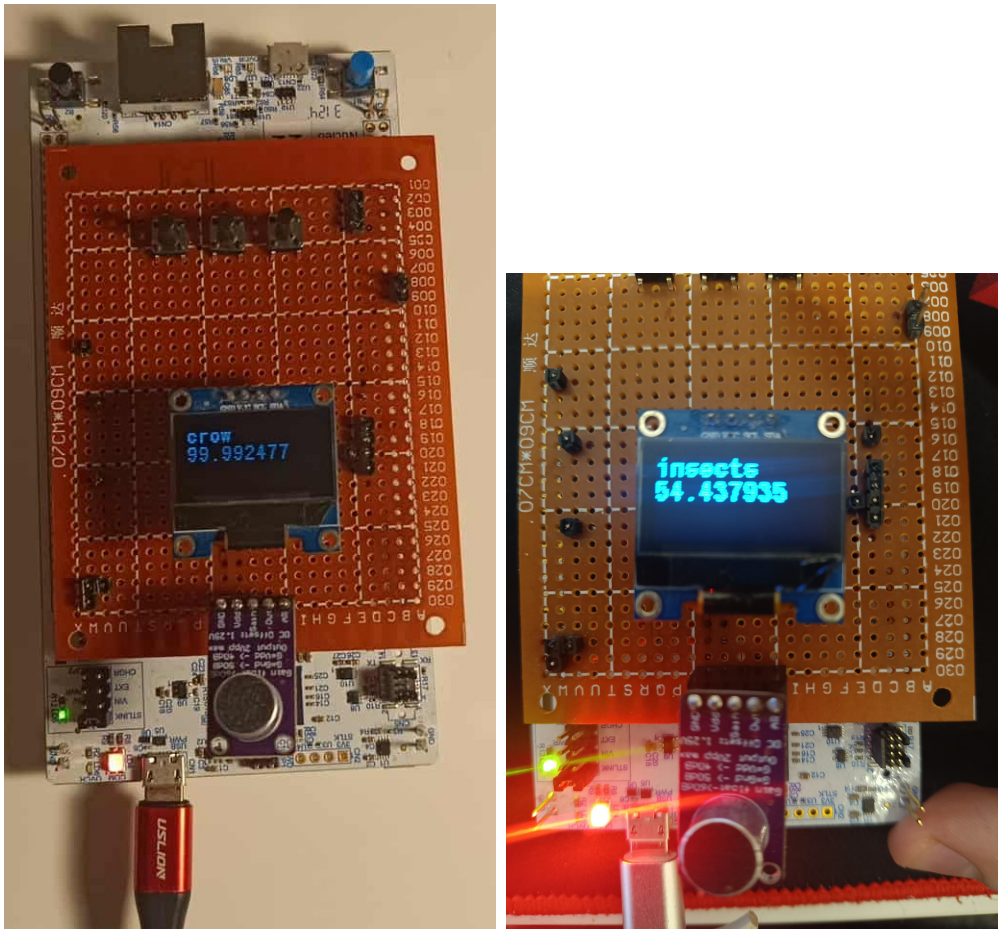

Rysunek 16: Działanie urządzenia

```
compute_mfcc_features DONE
MFCC features - first 10 (before normalization): -25.603018 3.282436 2.253441 1
019317 0.825541 1.255348 1.109038 0.299720 -0.131396 0.248947
MFCC features - first 10 (after normalization): 0.815420 -1.809178 2.130915 0.2
7107 1.729927 0.530378 2.309889 -0.339311 0.296686 -0.390769
Preparing in/out network...
Number of inputs: 1, input number: 1
size output: 80, size: 10
Network running...
Network run succesful
Result of prediction:
Class 0 (cat): 1.56%
Class 1 (cow): 0.18%
Class 2 (crow): 0.49%
Class 3 (dog): 2.50%
Class 4 (frog): 1.46%
Class 5 (hen): 0.13%
Class 6 (insects): 89.51%
Class 7 (pig): 3.06%
Class 8 (rooster): 0.20%
Class 9 (sheep): 0.91%
The highest propability: insects: 89.51%
run_inference finished.
```

Rysunek 17: Debugowanie urządzenia